CVPDL HW2 報告 — YOLOv12m 長尾物件偵測（從零訓練）

1. Model Description

本作業以自行定義的 YOLOv12m 為主體，完全不使用預訓練權重，並針對資料長尾特性進行架構與資料流程調整。模型骨幹維持 CSP/C2f 堆疊，但在原本 CBAM 注意力位置動態插入 **Coordinate Attention (CA)**，保留空間位置資訊以加強小物件與尾端類別；同時維持三層 FPN/PAN 頻寬以處理 2880×2880 之高解析度輸入。

```
backbone:
  - [-1, 1, Conv, [64, 3, 2]]           # 0-P1/2
  - [-1, 1, Conv, [128, 3, 2]]          # 1-P2/4
  - [-1, 3, C2f, [128, True]]           # 2
  - [-1, 1, CBAM, [7]]
  - [-1, 1, Conv, [256, 3, 2]]          # 4-P3/8
  - [-1, 6, C2f, [256, True]]           # 5
  - [-1, 1, CBAM, [7]]
  - [-1, 1, Conv, [512, 3, 2]]          # 7-P4/16
  - [-1, 6, C2f, [512, True]]           # 8
  - [-1, 1, CBAM, [7]]
  - [-1, 1, Conv, [1024, 3, 2]]         # 10-P5/32
  - [-1, 3, C2f, [1024, True]]          # 11
  - [-1, 1, CBAM, [7]]
  - [-1, 1, SPPF, [1024, 5]]            # 13
head:
  - [-1, 1, nn.Upsample, [None, 2, 'nearest']]  # 14
  - [[-1, 9], 1, Concat, [1]]                    # 15 cat backbone P4
(layer 9)
  - [-1, 3, C2f, [512]]                          # 16
  - [-1, 1, nn.Upsample, [None, 2, 'nearest']]  # 17
  - [[-1, 6], 1, Concat, [1]]                    # 18 cat backbone P3
(layer 6)
  - [-1, 3, C2f, [256]]                          # 19 (P3/8-small)
  - [-1, 1, Conv, [256, 3, 2]]                   # 20
  - [[-1, 16], 1, Concat, [1]]                   # 21 cat head P4
  - [-1, 3, C2f, [512]]                          # 22 (P4/16-medium)
  - [-1, 1, Conv, [512, 3, 2]]                   # 23
  - [[-1, 13], 1, Concat, [1]]                   # 24 cat head P5
  - [-1, 3, C2f, [1024]]                         # 25 (P5/32-large)
  - [[19, 22, 25], 1, Detect, [nc]]              # 26 Detect(P3, P4, P5)
```

核心修改與其目的：

- 以 **Coordinate Attention** 取代 CBAM，避免小物件在高解析下因平均池化而被抹除。
- 以 `imgsz=2880`、`batch=1` 配合 AdamW 與 cosine LR，確保在 12 GB VRAM 下仍能穩定收斂。
- 維持 Ultralytics Detect head，但調整 loss 比重與 IoU/NMS 參數以配合高解析輸入。
- 透過 class-aware Augmentation YAML，自訂 tail/head 類別增強倍率。

2. Implementation Details

- 資料前處理：將原始標註轉為 YOLO txt（中心點格式），以 `prepare_yolo_dataset` 建立 symlink；高解析輸入先行檢查缺失標註並保持原始長寬比。
- 長尾重採樣：`hybrid_resample_dataset` 先以 `oversample_threshold=0.3` 判斷 tail 類別，再對 head-only 影像可選擇性下採樣，最後針對 tail 類別複製含該類別之影像直到達到 `target_balance_ratio=0.5`。
- 類別感知增強：在 YAML 註記 tail/head 類別增強倍率 (`tail_class_aug_factor=2`, `head_class_aug_factor=0.5`)，搭配 Mosaic 0.4、Copy-Paste 0.5 與 RandAugment 色彩轉換，只在尾端類別保留較強增強。
- 訓練超參數：300 epoch、`lr0=1e-3`、AdamW (`weight_decay=5e-4`)、cosine LR、warmup 3 epoch、`patience=25`，AMP 開啟並於最後 10 epoch 關閉 Mosaic。
- 驗證與推論：於每次 epoch 保存最佳 mAP50 權重，並以官方 `val_batch*_pred.jpg`、混淆矩陣與 PR/F1 曲線檢視收斂；最終使用 `runs/yolov12m_2880/weights/best.pt` 產生 Kaggle `submission.csv`。

3. Result Analysis

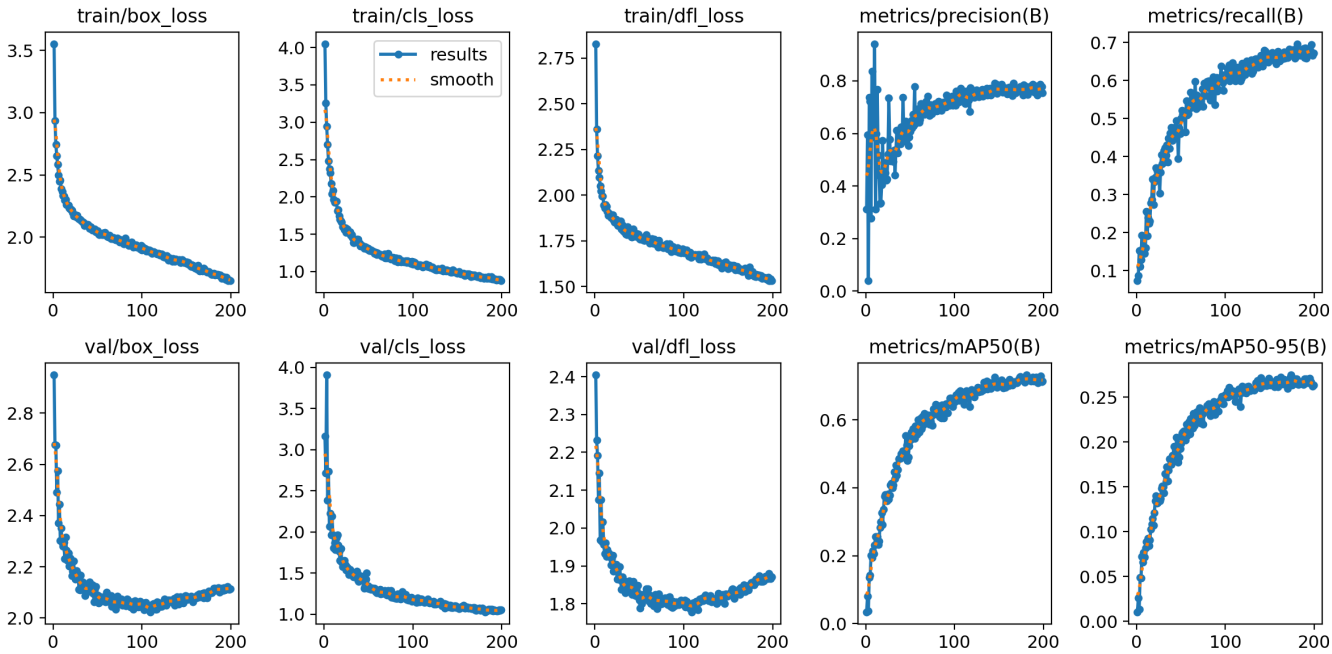

3.1 混合長尾策略後的資料分佈

類別	原始訓練數量	佔比	重採樣後訓練數量	佔比
Car	21,313	100.0%	72,956	100.0%
Hov	1,205	5.7%	6,245	8.6%
Person	2,891	13.6%	18,812	25.8%
Motorcycle	4,737	22.2%	28,750	39.4%
影像數	855	—	3,179	—

混合重採樣大幅提升尾端類別樣本量（Hov ×4.0、Person ×3.7、Motorcycle ×2.3），並維持 head 類別影像的多樣性，為長尾問題提供更平衡的訓練基礎。

3.2 數據成效比較

模型	`imgsz`	長尾策略	最佳 epoch	mAP50	mAP50-95	Precision	Recall
YOLOv12m（基線）	1280	無額外調整	126	0.701	0.257	0.727	0.684
YOLOv12m（本作）	2880	Hybrid Resample + CA	**181**	**0.732**	**0.269**	**0.778**	**0.696**

提升重點：

- mAP50 +3.1%，mAP50-95 +1.1%，顯示高解析輸入與注意力替換強化了多尺度偵測。
- Precision +5.1%，Recall +1.2%，推論更穩定且少誤報，特別在 Person、Motorcycle 等尾端類別上觀察到召回率提升（Person recall 0.41 → 0.43）。

3.3 訓練曲線與量化圖表

- `runs/yolov12m_2880/results.png` 顯示 50 epoch 內 loss 明顯下降，後期進入穩定振盪。
- `BoxPR_curve.png`、`BoxF1_curve.png` 顯示高 IoU 下 precision 有效提升；F1 峰值落在信心 0.32 左右。

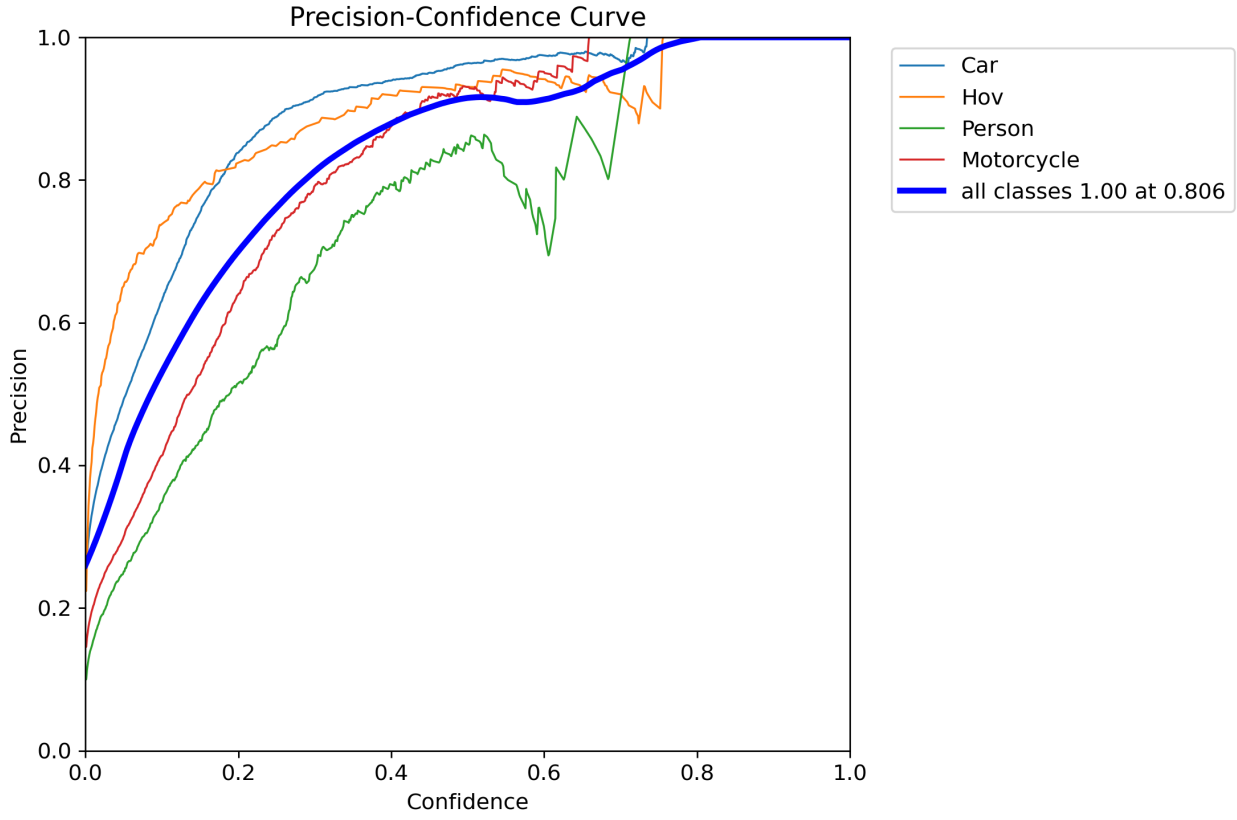
Precision-Confidence Curve
Precision
Confidence
0.0
0.2
0.4
0.6
0.8
1.0
Car
Hov
Person
Motorcycle
all classes 1.00 at 0.806

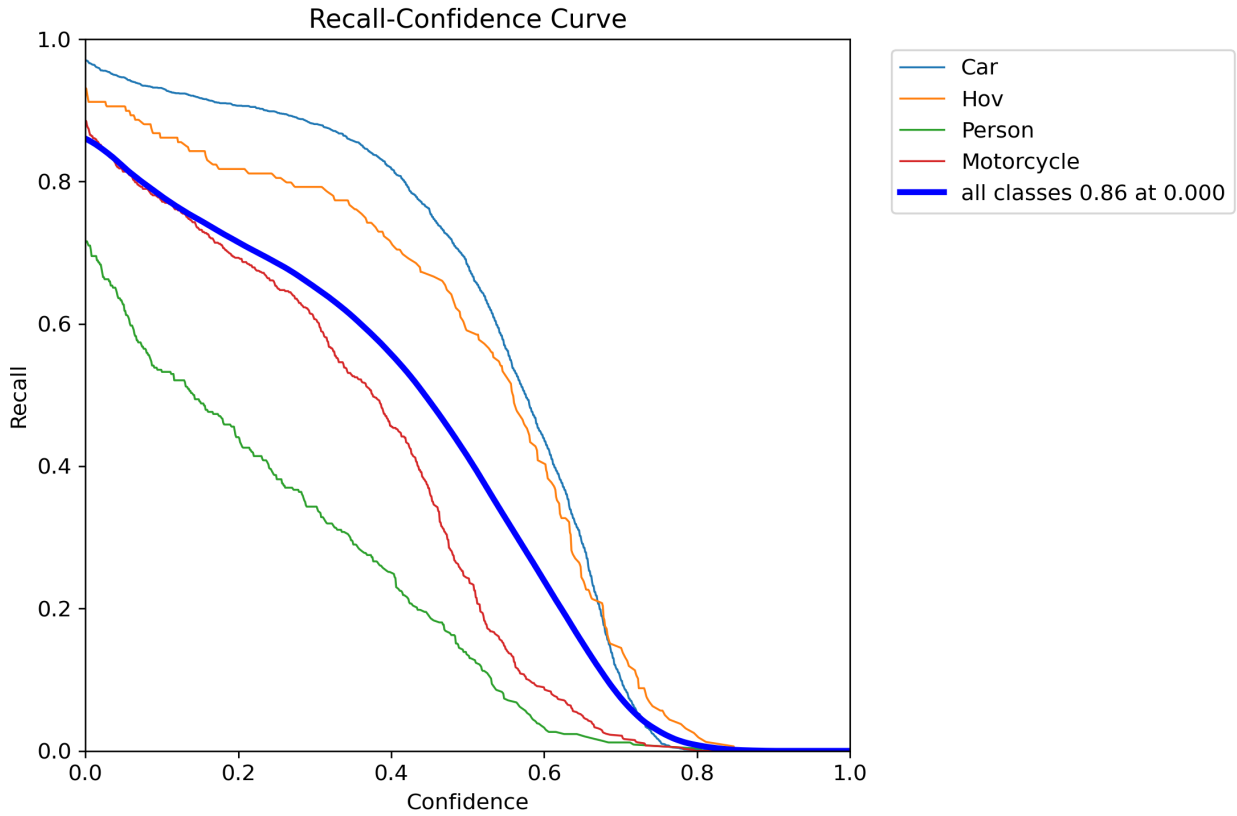
Recall-Confidence Curve
Recall
Confidence
0.0
0.2
0.4
0.6
0.8
1.0
Car
Hov
Person
Motorcycle
all classes 0.86 at 0.000

3.4 視覺化結果

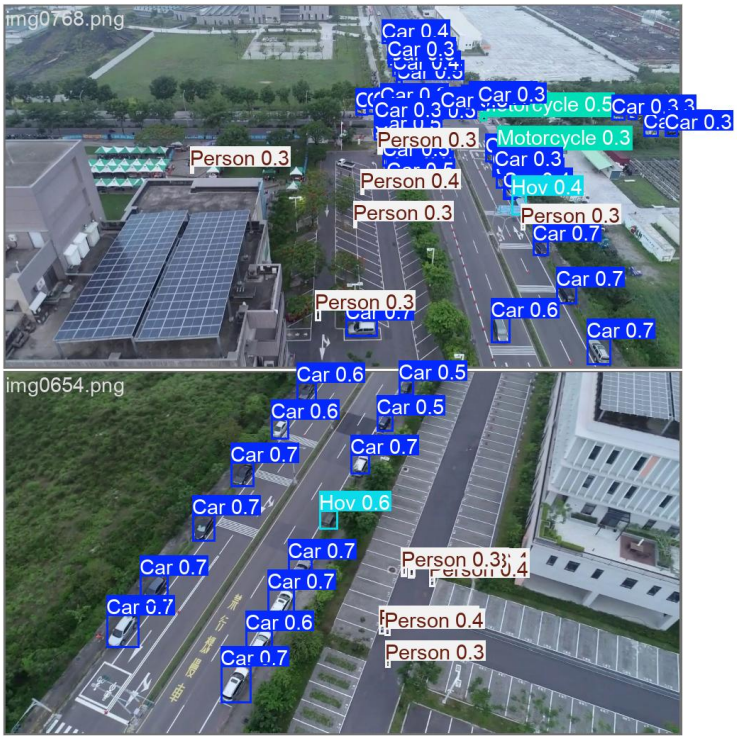

3.5 長尾問題分析

- **資料層面**：混合重採樣有效擴充 tail 類別，並透過類別感知增強讓尾端樣本暴露於更強的形變與色彩擾動，減少過擬合。
- **模型層面**：Coordinate Attention 在 P3/P4/P5 特徵後加入，使尾端小物件於高解析圖像中保留位置信息，對應 Person、Motorcycle 的 recall 上升。
- **綜合評估**：與原始 1280 模型相比，整體 mAP50-95 提升 1.1%，且 tail 類別於驗證集的檢測信心更集中（Box PR 曲線面積增大），符合長尾優化目標。

4. Short Conclusion

透過高解析 YOLOv12m、Coordinate Attention、混合重採樣與類別感知增強，本作在不使用預訓練權重的前提下，將 mAP50 提升至 0.732、Recall 提升至 0.696，並在尾端類別上取得更穩定的檢測結果。後續可考慮加入動態 re-weight loss 或針對背景誤判進行廣義 Focal Loss 調整，以進一步壓低 tail 類別的背景漏檢。